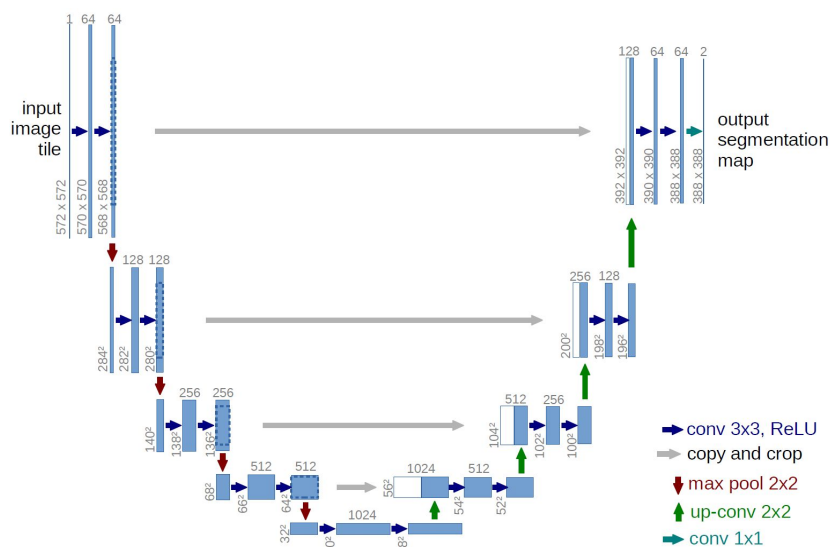


Wykrywanie naczyń dna siatkówki oka

Autorzy: 132267, 132300

1. Opis rozwiązania

W rozwiązaniu użyliśmy sieci konwolucyjnych o architekturze znanej jako U-Net. Technika ta jest oparta o tradycyjne sieci konwolucyjne a także nieco rozszerzona. Pozwala na segmentację obrazów i jak się okazuje świetnie nadaje się jako metoda wykrywania naczyń dna siatkówki oka. Wykorzystaliśmy przygotowaną i popularną implementację tego modelu w bibliotece Keras, która znajduje się tutaj: <https://github.com/zhixuhao/unet>. Hiperparametry uczenia (rozmiar wsadu, learning rate, liczba epok, itd) dobraliśmy metodą prób i błędów.



Poglądowa architektura U-Net, nieznacznie różniąca się od naszej
Źródło: <https://lmb.informatik.uni-freiburg.de/people/ronneber/u-net/>

Przed nauką modelu dane treningowe zostały dodatkowo przetworzone, aby zwiększyć skuteczność. Wykorzystana została metoda przetwarzania obrazów polegająca na poprawianiu kontrastu analizowanego obrazu z wykorzystaniem jego histogramu (z użyciem metody `cv2.equalizeHist`). Ponadto odjęliśmy od każdego piksela średnią z całego obrazu w celu normalizacji danych.

W celu uniknięcia przeuczenia wykorzystaliśmy metodę wielokrotnej walidacji skrośnej. Polega na podziale zbioru treningowego na k zrównoważonych podzbiorów, a następnie iteracyjne k -krotne uczenie modelu na $k-1$ podziorach oraz walidacji modelu na pozostałym podziorze. Dzięki niej mamy również możliwość pokazania predykcji modelu na wszystkich obrazach z wykorzystanej bazy (baza obrazów [STARE](#)).

2. Analiza trafności modelu

Za miarę analizy trafności wykorzystaliśmy miarę F1, która jest podana wzorem:

$$F1 = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Gdzie precision mówi nam o dokładności klasyfikacji w obrębie rozpoznanej klasy, natomiast recall mówi o tym, na ile nasz klasyfikator potrafi rozpoznać obiekty z danej klasy. Ponadto pomocniczo mierzyliśmy miary czułości (sensitivity) oraz swoistości (specificity). Miara dokładności (accuracy) słabo sprawdzała się na tym zbiorze danych z uwagi na niezrównoważenie rozmiaru klas decyzyjnych jednak również ją zawarliśmy w wynikach.

Wyniki przedstawiają się następująco:

```
im0162.ppm Acc: 0.94983, sensitivity: 0.71209, specificity: 0.97535, F1-score: 0.73346
im0139.ppm Acc: 0.94030, sensitivity: 0.67540, specificity: 0.96992, F1-score: 0.69470
im0235.ppm Acc: 0.95698, sensitivity: 0.71222, specificity: 0.98685, F1-score: 0.78265
im0255.ppm Acc: 0.94659, sensitivity: 0.65238, specificity: 0.98439, F1-score: 0.73556
im0004.ppm Acc: 0.93750, sensitivity: 0.41012, specificity: 0.98841, F1-score: 0.53604
im0044.ppm Acc: 0.95149, sensitivity: 0.63339, specificity: 0.98123, F1-score: 0.69067
im0001.ppm Acc: 0.94479, sensitivity: 0.59948, specificity: 0.98202, F1-score: 0.67881
im0081.ppm Acc: 0.96489, sensitivity: 0.81794, specificity: 0.98001, F1-score: 0.81298
im0163.ppm Acc: 0.96149, sensitivity: 0.79468, specificity: 0.97937, F1-score: 0.79983
im0291.ppm Acc: 0.96837, sensitivity: 0.59678, specificity: 0.99303, F1-score: 0.70132
im0082.ppm Acc: 0.95193, sensitivity: 0.75113, specificity: 0.97405, F1-score: 0.75613
im0240.ppm Acc: 0.93941, sensitivity: 0.56221, specificity: 0.99114, F1-score: 0.69117
im0005.ppm Acc: 0.94567, sensitivity: 0.63344, specificity: 0.98340, F1-score: 0.71544
im0239.ppm Acc: 0.95275, sensitivity: 0.65799, specificity: 0.98830, F1-score: 0.74986
im0319.ppm Acc: 0.95931, sensitivity: 0.35157, specificity: 0.99420, F1-score: 0.48404
im0002.ppm Acc: 0.92771, sensitivity: 0.18854, specificity: 0.99453, F1-score: 0.30189
im0236.ppm Acc: 0.93286, sensitivity: 0.45239, specificity: 0.99241, F1-score: 0.59774
im0003.ppm Acc: 0.93430, sensitivity: 0.61573, specificity: 0.95995, F1-score: 0.58270
im0077.ppm Acc: 0.94689, sensitivity: 0.59708, specificity: 0.98582, F1-score: 0.69246
im0324.ppm Acc: 0.94210, sensitivity: 0.37434, specificity: 0.99083, F1-score: 0.50546
```

Średnia metryk:

Acc: 0.94776, F1-score: 0.66215

Sensitivity: 0.58944, Specificity: 0.98376

3. Porównanie wyników z klasyfikatora opartego na prostych transformacjach obrazów

W klasyfikatorze opartym na prostych transformacjach początkowo usunęliśmy tło obrazu (gdyż w dalszych krokach na tych powierzchniach zostawały niepoprawnie wykrywane naczynia dna oka). Następnie stosowane zostało rozmywanie obrazu filtrem Gaussa, a w kolejnym kroku aplikowana była detekcja krawędzi metodą Canny.

```
im0162.ppm Acc: 0.90423, sensitivity: 0.65027, specificity: 0.92372, F1-score: 0.49181
im0139.ppm Acc: 0.91904, sensitivity: 0.24565, specificity: 0.97793, F1-score: 0.32797
im0235.ppm Acc: 0.90890, sensitivity: 0.42752, specificity: 0.95594, F1-score: 0.45520
im0255.ppm Acc: 0.90858, sensitivity: 0.55362, specificity: 0.94347, F1-score: 0.52016
im0004.ppm Acc: 0.92582, sensitivity: 0.00032, specificity: 0.99993, F1-score: 0.00064
im0044.ppm Acc: 0.82911, sensitivity: 0.43026, specificity: 0.85897, F1-score: 0.25965
im0001.ppm Acc: 0.89805, sensitivity: 0.09341, specificity: 0.96783, F1-score: 0.12758
im0081.ppm Acc: 0.91110, sensitivity: 0.37353, specificity: 0.95447, F1-score: 0.38549
im0163.ppm Acc: 0.91215, sensitivity: 0.59323, specificity: 0.93888, F1-score: 0.51087
im0291.ppm Acc: 0.95125, sensitivity: 0.16481, specificity: 0.99314, F1-score: 0.25482
im0082.ppm Acc: 0.90679, sensitivity: 0.59105, specificity: 0.93375, F1-score: 0.49938
im0240.ppm Acc: 0.89866, sensitivity: 0.03971, specificity: 0.99634, F1-score: 0.07408
im0005.ppm Acc: 0.90372, sensitivity: 0.54808, specificity: 0.93903, F1-score: 0.50701
im0239.ppm Acc: 0.90476, sensitivity: 0.34309, specificity: 0.95785, F1-score: 0.38354
im0319.ppm Acc: 0.95737, sensitivity: 0.19523, specificity: 0.99169, F1-score: 0.28297
im0002.ppm Acc: 0.90943, sensitivity: 0.14653, specificity: 0.96386, F1-score: 0.17729
im0236.ppm Acc: 0.90900, sensitivity: 0.38803, specificity: 0.96089, F1-score: 0.43582
im0003.ppm Acc: 0.92844, sensitivity: 0.29923, specificity: 0.96849, F1-score: 0.33356
im0077.ppm Acc: 0.90056, sensitivity: 0.52129, specificity: 0.93361, F1-score: 0.45661
im0324.ppm Acc: 0.93350, sensitivity: 0.00389, specificity: 0.99997, F1-score: 0.00775
```

Średnia metryk:

Acc: 0.91102, F1-score: 0.32461

Sensitivity: 0.33044, Specificity: 0.95799

Z analiz obu metod widoczna jest zdecydowana przewaga metody opartej na sieciach konwolucyjnych. Metoda ta również lepiej się generalizuje i jest łatwiejsza do zaaplikowania na większych zbiorach danych.

4. Wyniki klasyfikatora opartego na metodzie U-Net

